Reporte de resultados

1. Sintesis de resultados por avance

Avance 1 – Regresion Logistica

Evaluacion del modelo:

ROC-AUC: 0.7511

Accuracy: 0.71

Precision: 0.38

Recall: 0.67

F1-Score: 0.49

PR AUC: 0.3882

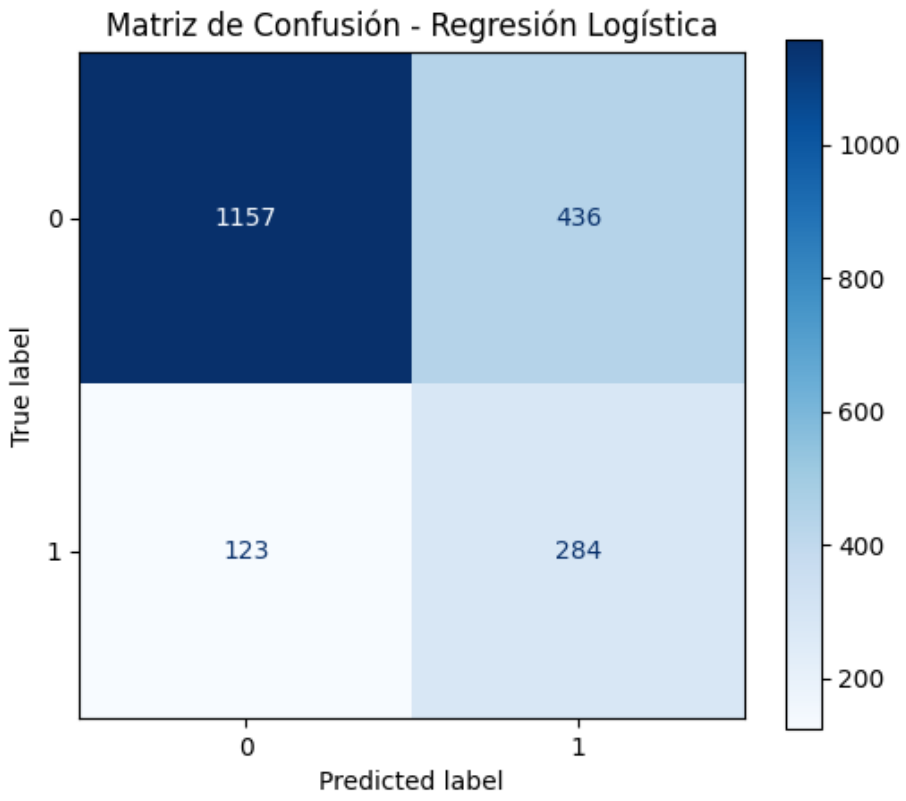

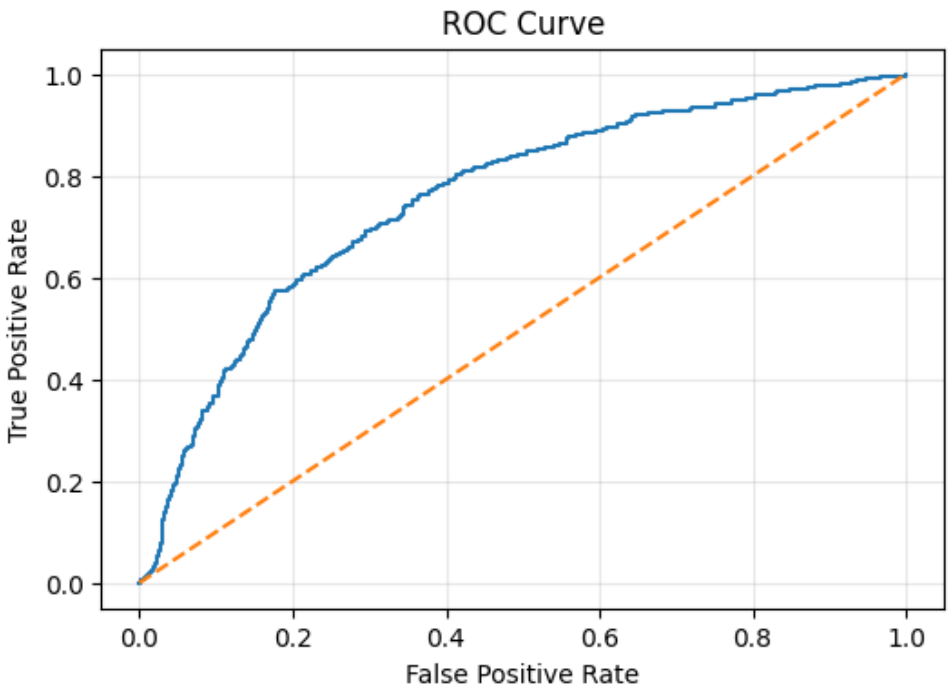

=== Interpretacion de las metricas: ===

¿Por qué Accuracy NO es la mejor métrica aquí?

- Dataset desbalanceado: se visualiza en un dataset con target de un 79,63% sin churn = 0 y un 20,37% con churn = 1. Por lo tanto, un modelo que prediga siempre 'no-churn' tendría ~79% accuracy.

Métricas más importantes para churn:

* Recall: % de clientes que realmente van a hacer churn que identificamos

* Precision: % de predicciones de churn que son correctas

* ROC AUC: Capacidad de discriminación general

* PR AUC: Rendimiento en clase minoritaria (churn)

=== Las características más importantes que afectan el churn: ===

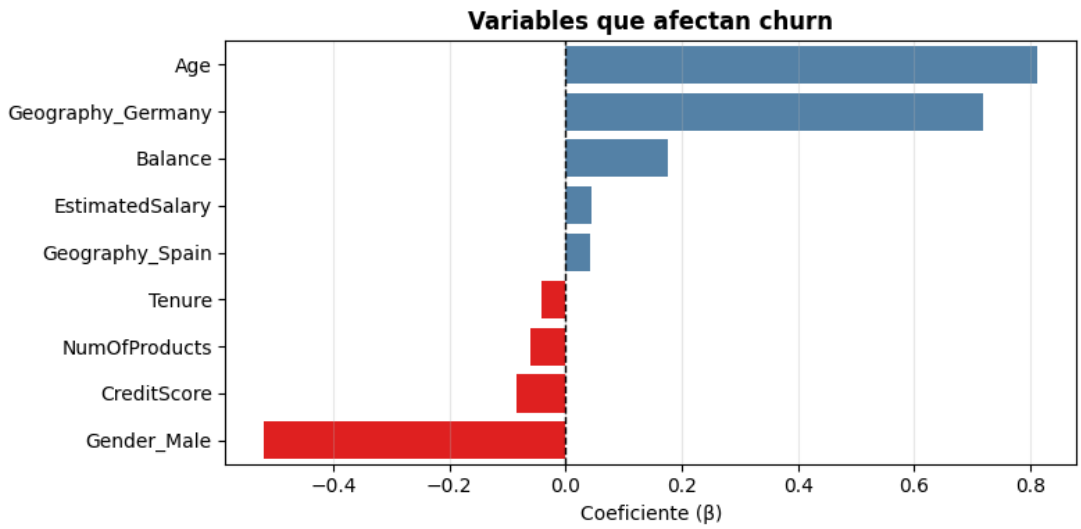

	feature	coef	odds_ratio
1	Age	0.812765	2.254132
6	Geography_Germany	0.718264	2.050870
3	Balance	0.176489	1.193021
5	EstimatedSalary	0.045589	1.046644
7	Geography_Spain	0.042362	1.043272
2	Tenure	-0.042233	0.958646
4	NumOfProducts	-0.061409	0.940439
0	CreditScore	-0.085581	0.917979
8	Gender_Male	-0.519207	0.594992

=== INTERPRETACIÓN DE COEFICIENTES Y ODDS RATIOS ===

Coeficientes en Regresión Logística:

- Coeficiente positivo: aumenta la probabilidad de churn

- Coeficiente negativo: disminuye la probabilidad de churn

- Magnitud: qué tanto influye la variable

=== Algunas conclusiones de Odds Ratios (e^coeficiente): ===

- Age: si aumenta, aumenta un 220% la probabilidad de que surga el churn.

- Geography_Germany: si es Geography_Germany aumenta un 215% la probabilidad de que surga el churn.

- Gender_Male: que sea de genero masculino **reduce** un 43% las probabilidad de churn.

=== Interpretación de Intervalos de Confianza: ===

- Si el IC no incluye 0: el efecto es estadísticamente significativo

- Amplitud del IC: indica la precisión de la estimación

- IC estrechos = mayor precisión, IC amplios = menor precisión

=== INTERVALOS DE CONFIANZA (95%) ===

Age [IC: 0.76, 0.86]

Geography_Germany [IC: 0.66, 0.77]

Balance [IC: 0.12, 0.22]

EstimatedSalary [IC: -0.01, 0.1]

Geography_Spain [IC: -0.01, 0.09]

Tenure [IC: -0.09, 0.01]

NumOfProducts [IC: -0.17, 0.05]

CreditScore [IC: -0.19, 0.01]

Gender_Male [IC: -0.59, -0.44]

=== RESUMEN DE RESULTADOS ===

El modelo de regresión logística logró un ROC AUC de 0.7511 Esto indica una capacidad buena para discriminar entre clientes que harán churn y los que no.

El PR AUC de 0.3882 muestra el rendimiento específico en la clase minoritaria (churn)

Avance 2 – Gradient Boosting (Optimización)

A continuación, se muestra una comparación de los resultados utilizando validación cruzada (cv):

=== EVALUACIÓN INICIAL CON VALIDACIÓN CRUZADA ===

```
Evaluando Random Forest...
ROC AUC: 0.8453 (±0.0076)
F1-Score: 0.5884 (±0.0113)
Tiempo: 13.81s

Evaluando XGBoost...
ROC AUC: 0.8535 (±0.0094)
F1-Score: 0.5700 (±0.0186)
Tiempo: 2.35s

Evaluando CatBoost...
ROC AUC: 0.8673 (±0.0110)
F1-Score: 0.5778 (±0.0181)
Tiempo: 6.77s

Evaluando LightGBM...
ROC AUC: 0.8539 (±0.0115)
F1-Score: 0.5983 (±0.0148)
Tiempo: 6.79s
```

=== TABLA COMPARATIVA DE RESULTADOS ===

	ROC_AUC	PR_AUC	Accuracy	Precision	Recall	F1
Stacking	0.880554	0.729019	0.825333	0.526570	0.767606	0.624642
CatBoost	0.877183	0.726131	0.884000	0.780612	0.538732	0.637500
XGBoost_Optuna	0.876862	0.729805	0.884667	0.840491	0.482394	0.612975
LightGBM	0.876529	0.714436	0.820667	0.518072	0.757042	0.615165
XGBoost_Base	0.870523	0.704196	0.874000	0.736318	0.521127	0.610309
XGBoost_GridSearch	0.870523	0.704196	0.874000	0.736318	0.521127	0.610309
RandomForest	0.854554	0.701239	0.810000	0.498778	0.718310	0.588745

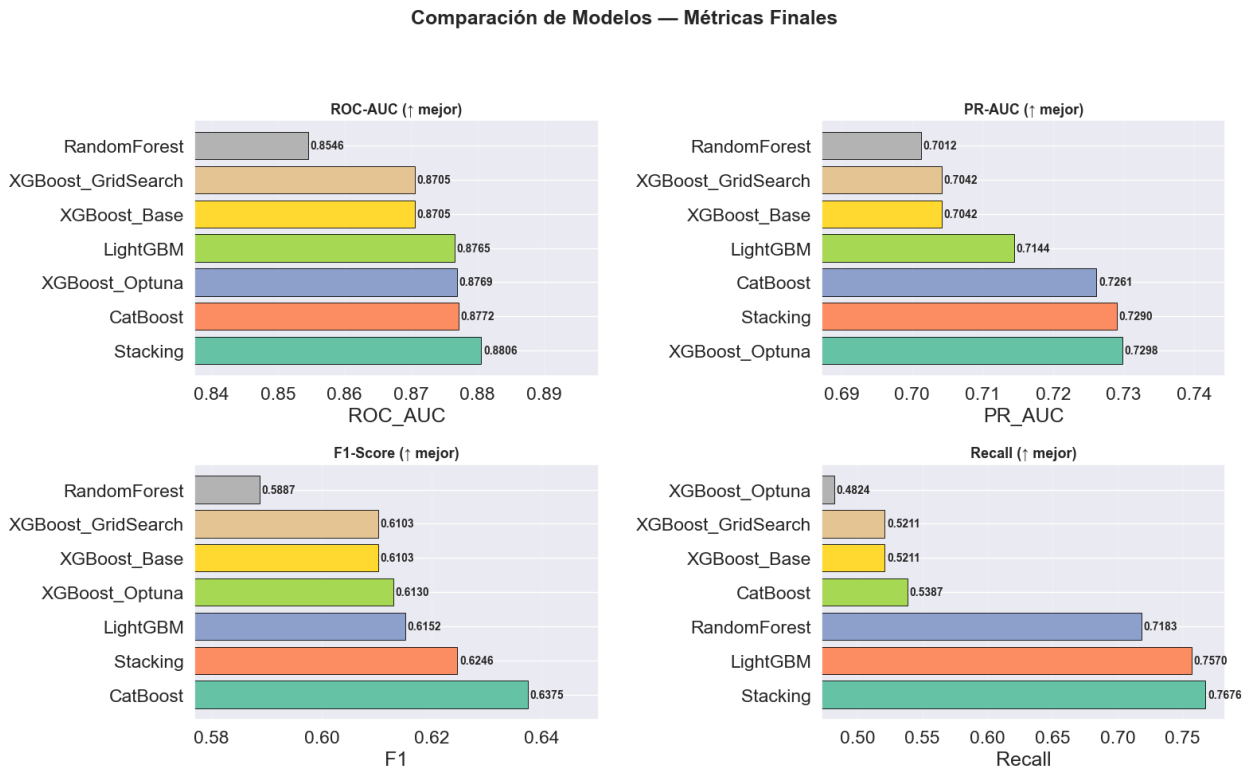

El modelo Stacking supera al resto en la mayoría de las métricas relevantes, especialmente en ROC-AUC y Recall, lo que lo convierte en la mejor opción para un sistema de detección de churn pero a un alto costo de computo ya que realiza la combinación de varios modelos y debe aprender a como mezclar mejor sus predicciones. En lugar de promediar resultados (como en bagging) o votar (como en voting), el stacking aprende cuál modelo confiar más según el caso.

XGBoost optimizado con Optuna muestra un desempeño muy competitivo y destaca en PR-AUC, siendo una excelente alternativa más simple y eficiente computacionalmente.

CatBoost presenta el mejor F1-score, lo que lo posiciona como un modelo balanceado, aunque con menor capacidad de detección de churners que Stacking.

En un contexto de negocio donde el *objetivo es minimizar la pérdida de clientes*, se recomienda utilizar **Stacking como modelo final**, priorizando Recall sin sacrificar capacidad predictiva global.

=== Las 10 variables más importantes de este modelo son ===

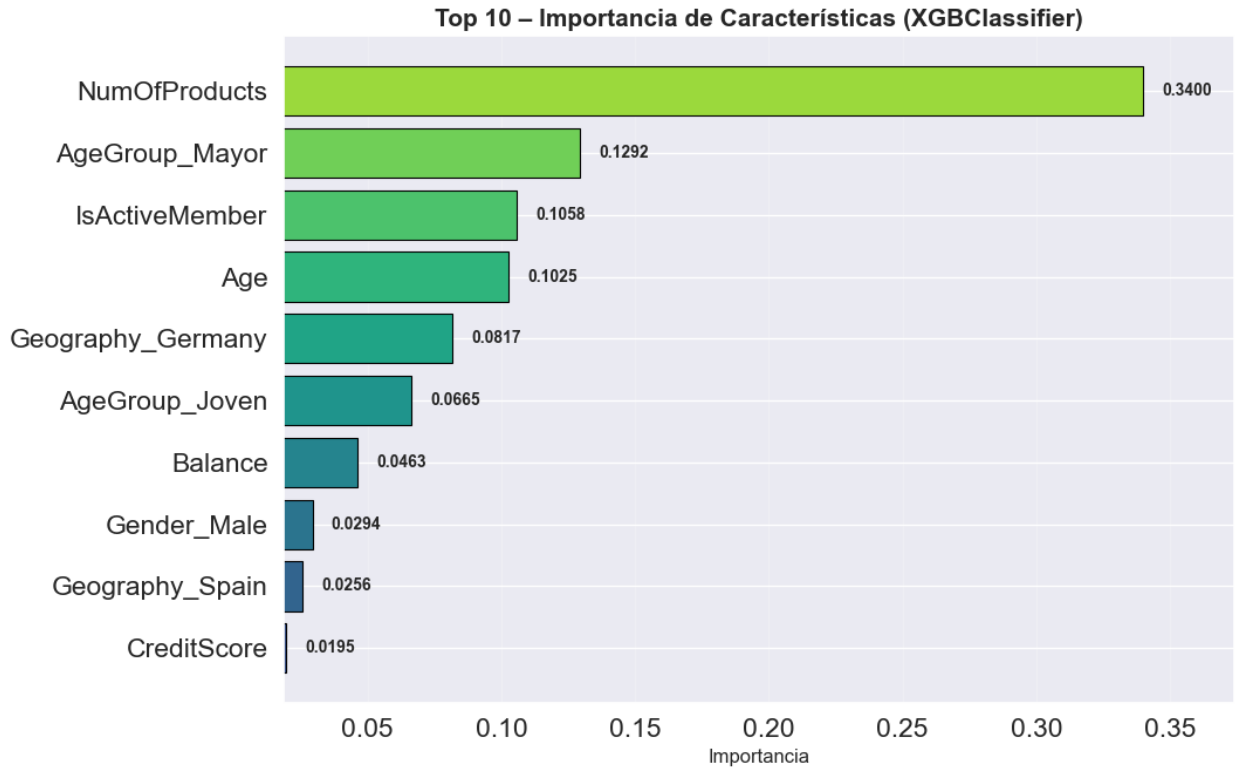

- La cantidad de productos (*NumOfProducts*) es el factor más determinante del churn.

- La *edad* y los *grupos de edades* explican una parte sustancial del riesgo de abandono.

- La actividad del cliente (*IsActiveMember*) es un fuerte predictor de churn.

- Existen diferencias relevantes por *país*, especialmente en Alemania.

- El *balance*, el *género* y el *credit score* tienen un impacto menor en la predicción

Avance 3 – Aprendizaje No Supervisado (Clustering)

=== DBSCAN: ===

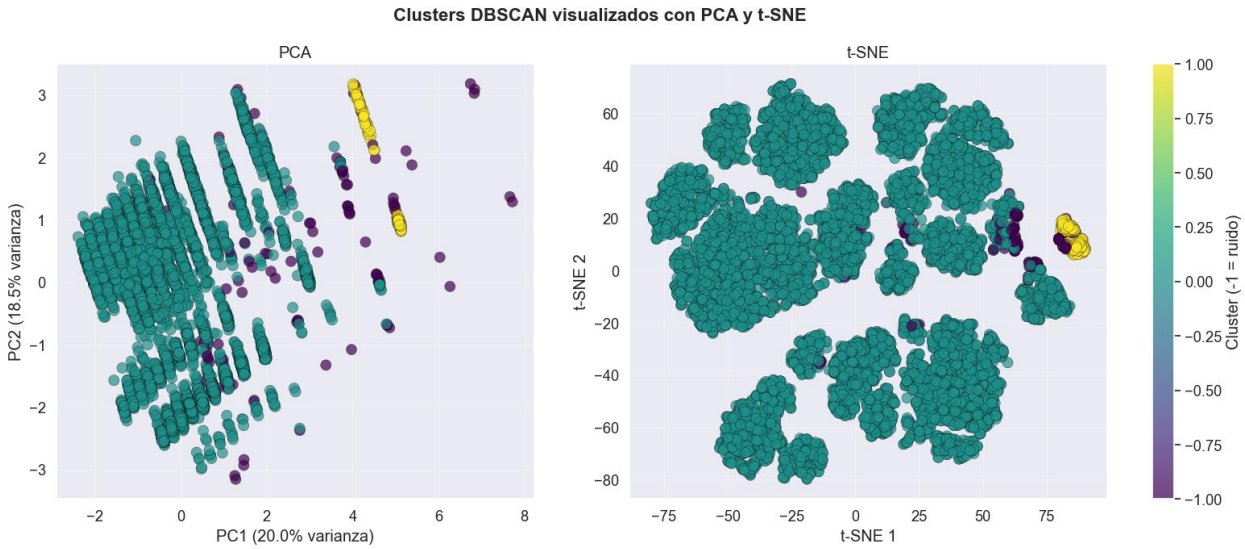

Se puede visualizar en el grafico que cada punto es un cliente:

- -1 (morado oscuro) → ruido / outliers
- 0 (verde-azulado) → cluster principal
- 1 (amarillo) → cluster secundario chico

En PCA:

- Casi todos los puntos están mezclados en una gran nube
- Un pequeño grupo (amarillo) aparece separado a la derecha

- Algunos puntos dispersos → ruido real

En t-SNE:

- Hay muchas “islas visuales”
- Pero todas esas islas tienen el mismo color (cluster 0)
- Solo una islita compacta (amarilla) es cluster 1

- Puntos violeta sueltos → ruido

En conclusión: DBSCAN NO encontró 3, 4 o 5 clusters bien definidos.

=== KMeans ===

Kmeans identificó 3 segmentos distintos de clientes (k = 3, es decir, 3 clusters o grupos), con un índice de Silhouette score de 0,199.

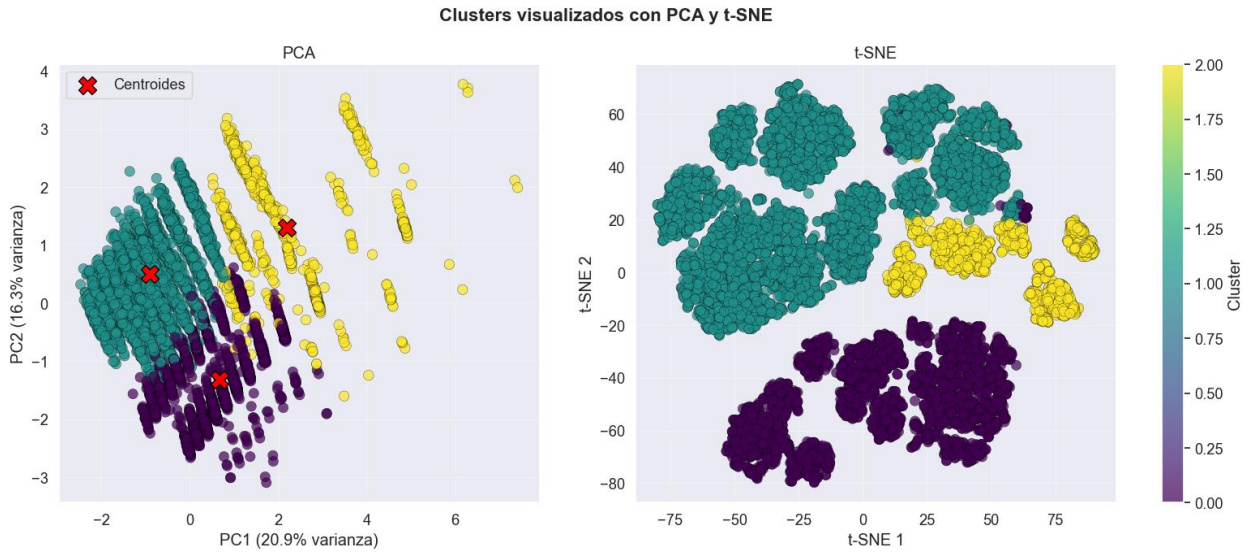

PCA: Se visualiza la división de los 3 clúster, existiendo así algunos solapamientos. Debemos tener en cuenta, que no se están distinguiendo los outliers.

T-sne: La estructura de 3 clúster bien marcados, no parece una segmentación forzada.

Conclusión elección K=3: se considera una buena elección. En t-SNE se ven exactamente 3 macro grupos naturales y no hay evidencia visual de que falte un clúster o que haya uno partido en dos.

Por lo tanto, se decide continuar trabajando con el modelo de Kmeans.

=== Las características de los segmentos identificados fueron: ===

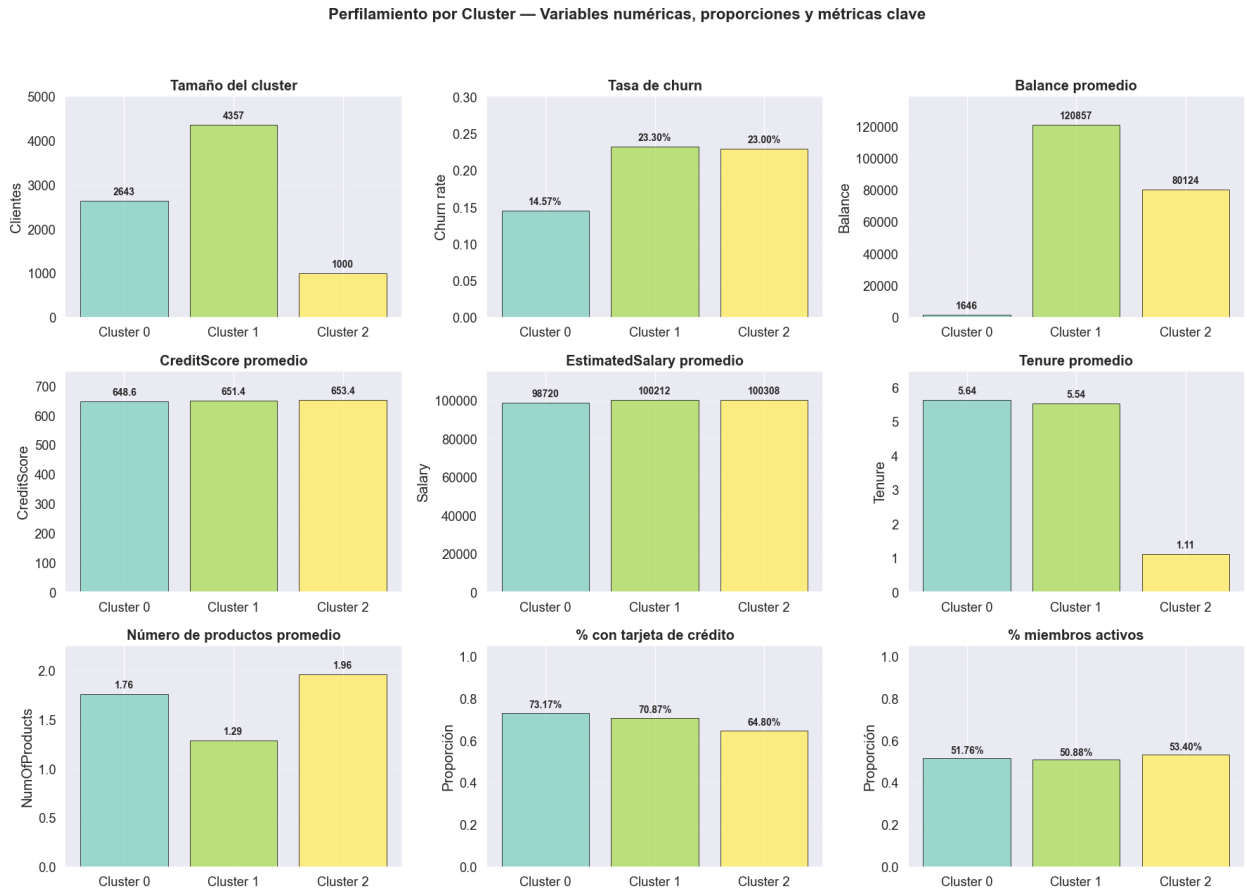

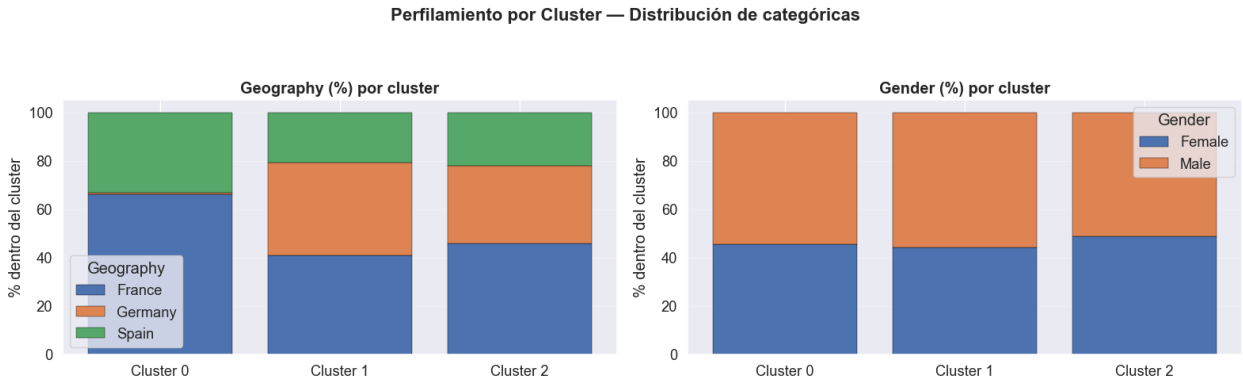

- **Similitudes**: entre los 3 clusters contienen un porcentaje en las siguientes variables:

  - *generos* siendo la 50% masculino y 50% feminino

  - *miembros activos* es del ~52%

  - **Salario estimado promedio* es de ~$100.000

  - *Credit score* es de ~650

- **Diferencias**:

  - *Size*: cluster 1 contiene el 54% de los clientes, cluster 0 el 33.04% y el cluster 2 el 12.50%

  - *Tasa de churn:* cluster 0 contiene un 16% en la tasa de churn, mientras que los clusters 1 y 2 contienen un 23% de abandonos.

  - *Balance*: cluster 0 1600, cluster 1 120.000 y cluster 2 80.000

  - *Tenere (años de antiguedad) promedio*: cluster 0 y 1 contiene 5,6 años en promedio mientras que el cluster 2 contiene 1,11.

  - *Numero de productos promedio*: cluster 2 contiene un promedio de 1.96, cluster 0 contiene 1.76 y el cluster 1 contiene en promedio 1.29.

  - *% con credit card*: cluster 0 contiene 73%, cluster 1 contiene 70% y cluster 2 contiene 64%.

  - *Geografia*: se puede destacar que en cluster 0 la mayor dominancia la tiene Francia 66% y 33% España, Alemania con 1% casi que no pertenece a este cluster. Los clusters 1 y 2 son muy similares en cuanto a la distribucion con ~40% Francia, ~40% Alemania y 20% España

Por otro lado, las features derivadas del clustering fueron:

1. Cluster_1 (i=0 a 2): Variables dummy para cada cluster
2. Distance_to_Centroid: Distancia al centroide del cluster asignado
3. Distance_to_HighRisk_Cluster: Distancia al cluster de mayor riesgo
4. Is_HighRisk_Cluster: Indicador binario de cluster de alto riesgo
5. Cluster_Risk_Score: Tasa de churn histórica del cluster

Y su correlación con la variable objetivo es:

Distance_to_Centroid: 2.53

Distance_to_HighRisk_Cluster: 3.06

Is_HighRisk_Cluster: 0.54

Cluster_Risk_Score: 0.20

Cluster de mayor riesgo de churn: 1

Algunas conclusiones generales son:

1. Segmentación

   Tasa de churn por cluster en KMeans

   cluster 0 -> 0.156530

   cluster 1 -> 0.230428

   cluster 2 -> 0.202141

2. Clustering:

   • K-Means identificó 3 segmentos distintos de clientes

• DBSCAN encontró 2 clusters, el cluster 0 con 7779 (97%) y el cluster 1 con 116 (1.45%) con 105 outliers y los hiperparametros fueron eps=2.2000, min_samples=8.
Interpretamos que:
- Los datos son más bien homogéneos
- No hay fronteras claras entre perfiles
- Solo hay outliers reales y un microsegmento raros

- === EVALUACIÓN FINAL DE CLUSTERING ===

  --- K-MEANS ---

  N° de clusters : 3

  Silhouette Score : 0.19

  Calinski-Harabasz : 1560.30

  Davies-Bouldin : 1.76

  --- DBSCAN ---

  N° de clusters : 2

  Proporción de ruido : 1.31%

  Silhouette (sin ruido): 0.37

  Calinski-Harabasz : 400.73

  Davies-Bouldin : 0.92

  Silhouette Score (↑ mejor): qué tan bien separado está cada punto de su propio cluster

  - K-Means: 0.199

  - DBSCAN: 0.370 (mejor)

  Calinski-Harabasz (↑ mejor): qué tan compactos son los clusters internamente

  - K-Means: 1560 (mejor)

  - DBSCAN: 401

Davies-Bouldin (↓ mejor): Penaliza clusters que están muy mezclados entre sí.

K-Means: 1.764

DBSCAN: 0.928 (mejor)

Número de clusters: K-Means genera 3 segmentos interpretables. DBSCAN colapsa todo en: 1 mega-cluster y 1 mini-cluster raro

Aunque DBSCAN gana en Silhouette y Davies-Bouldin, eso no significa que sea mejor para tu problema.

3. FEATURES DERIVADAS:

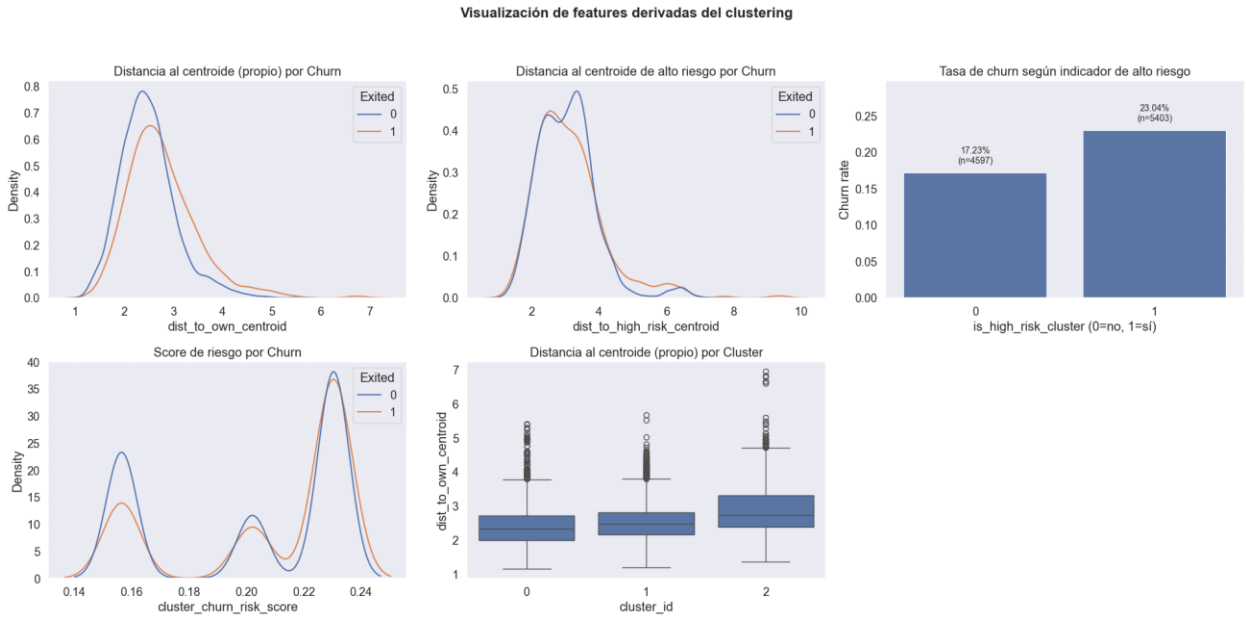

Distancia al centroide propio:
Los clientes que hacen churn suelen estar más alejados del centroide de su cluster, lo que indica que cuanto más "atípico" es un cliente dentro de su grupo, mayor es su riesgo de abandono

4. VISUALIZACIÓN

- PCA: Primeras 2 componentes explican 37.1% de varianza

• t-SNE: Mejor separación visual de clusters que PCA
• Se requieren 11 componentes PCA para 95% de varianza

2. Lecciones aprendidas

- ¿Cuándo usar modelos supervisados vs no supervisados?

  Podemos usar modelos supervisados cuando exista un target y además queremos predecir un resultado. En cambio, podemos utilizar modelos no supervisados cuando no nos indican el target (o la quitamos) y queremos *realizar segmentaciones* de datos con el objetivo de buscar patrones ocultos dentro de los datos.

- ¿Qué tipo de modelo es mejor en este caso?

  Para el realizar las predicciones de los resultados (Aprendizaje supervisado) podríamos decir que el mejor modelo seria el stacking con los modelos de XGB_Optuna, LightGBM, CatBoost

  Para el realizar las segmentaciones de los clientes (Aprendizaje No Supervisado) podríamos decir que el mejor modelo seria el KMeans con K = 3.

- ¿Aporto el análisis no supervisado?

  El aprendizaje no supervisado aporto 3 tipos de clientes:

  - Clientes fieles y estables
  - Clientes de alto valor en riesgo
  - Clientes nuevos e inestables

  Esto nos permitiría en el futuro hacer campañas personalizadas, distintos tipos de incentivos o promociones personalizadas según el tipo de cliente al cual nos estemos dirigiendo.

- Consideraciones para futuros proyectos de churn

  No quedarse solo con modelos supervisados sino que también usar **clustering + ML supervisado.** Esto da contexto de “perfil de cliente” que los modelos solos no capturan.

  Evaluar los modelos con múltiples métricas y no solamente tener en cuenta el Accuracy.

A futuro, se podría también hacer un EDA para cada cluster para obtener distintas predicciones según el tipo de cliente.

Para el aprendizaje no supervisado usar Stacking cuando:

- Hay mejora clara en PR-AUC / Recall
- Hay alto impacto de negocio por cada churn evitado

Si no, preferir:

- Un XGBoost bien tuneado + features de cluster
  (mejor balance entre performance, explicabilidad y costo).

Ajustar el threshold según objetivo:

- Maximizar Recall
- Maximizar F1
- Minimizar costo de churn.

Por último, optimizar sin sobreajustar es clave y la simplicidad es mejor que la complejidad cuando la diferencia es chica en las métricas.